ASIGNACIÓN

Despliegue de una API de predicción en Google Cloud Platform (GCP)

Objetivo Construir y desplegar una API de predicción con FastAPI, empaquetando la aplicación y el modelo dentro de una imagen Docker, almacenándola en Artifact Registry y ejecutándola en Cloud Run.	Integración La API consume datos desde BigQuery, ejecuta el modelo incluido en el proyecto y almacena las predicciones en una tabla de BigQuery.

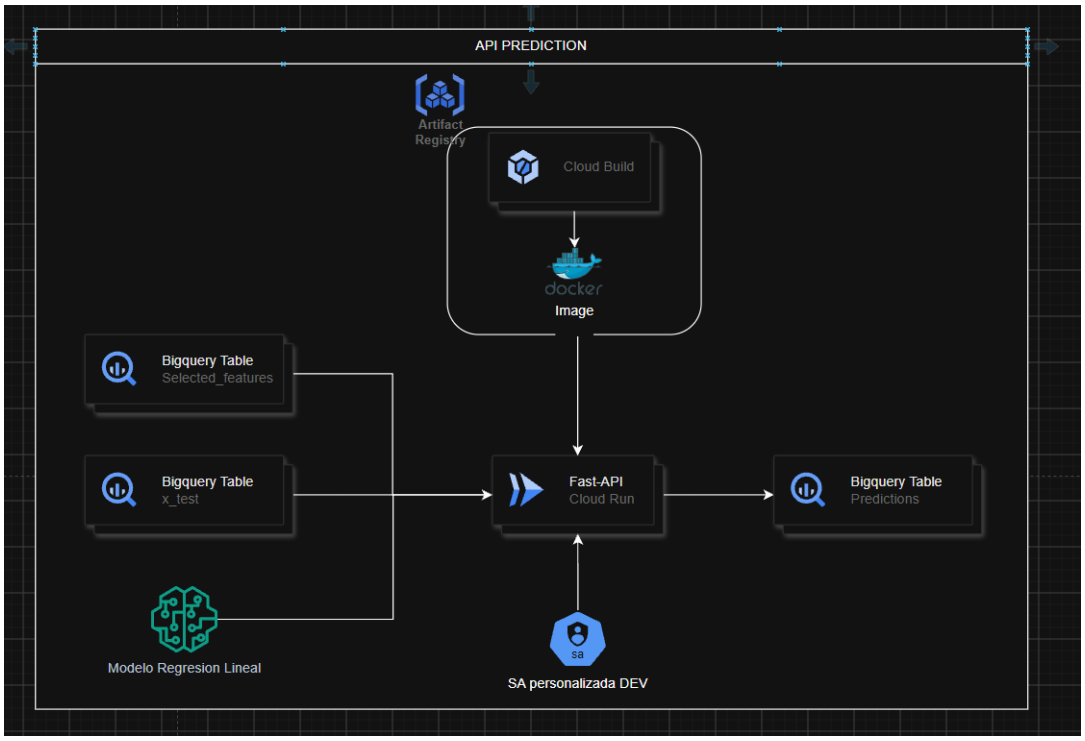
1. Objetivo de la asignación

Implementar un flujo completo de inferencia en GCP. El estudiante deberá utilizar un modelo de regresión lineal disponible como archivo dentro del proyecto, construir una API con FastAPI que lo cargue y genere predicciones, y desplegar dicha API en Cloud Run.

La solución deberá leer los datos necesarios desde BigQuery y registrar los resultados de la predicción en una tabla de BigQuery. La ejecución de Cloud Run deberá realizarse utilizando una cuenta de servicio personalizada.

2. Arquitectura de referencia

La siguiente imagen muestra el flujo esperado de la solución:



Flujo: BigQuery (entrada) → FastAPI en Cloud Run → modelo incluido en la imagen → predicción → BigQuery (salida).

3. Requerimientos técnicos

Componente	Requerimiento
Modelo	Debe estar incluido dentro de los archivos del proyecto y ser cargado localmente por la API. No se requiere un servicio independiente para servir el modelo.
API	Desarrollar la API utilizando FastAPI y exponer al menos un endpoint funcional de predicción.
BigQuery — entrada	La API debe consumir los datos requeridos desde una tabla de BigQuery.

Componente	Requerimiento
BigQuery — salida	Las predicciones generadas deben almacenarse en una tabla de BigQuery.
Docker	Crear un Dockerfile que incluya la aplicación, el modelo y todos los archivos necesarios para ejecutar la API.
Dependencias	Incluir un requirements.txt con las librerías necesarias.
Cloud Build	Utilizar Cloud Build para construir la imagen Docker.
Artifact Registry	Almacenar la imagen construida en un repositorio de Artifact Registry.
Cloud Run	Desplegar la imagen de la API en Cloud Run.
Cuenta de servicio	Configurar Cloud Run para ejecutar la aplicación utilizando una cuenta de servicio personalizada. Para esta asignación no se establece una restricción específica sobre los permisos de dicha cuenta.

4. Flujo de implementación esperado

#	Etapa	Actividad
1	Preparar el proyecto	Organizar el código de FastAPI, el modelo y los archivos necesarios.
2	Implementar la API	Crear el endpoint y la lógica para preparar datos, ejecutar el modelo y generar la predicción.
3	Integrar BigQuery	Leer los datos de entrada y guardar las predicciones en la tabla de salida.
4	Crear Dockerfile	Empaquetar aplicación, dependencias, modelo y archivos requeridos.
5	Construir imagen	Utilizar Cloud Build para generar la imagen Docker.
6	Publicar imagen	Guardar la imagen en Artifact Registry.
7	Desplegar	Desplegar la imagen en Cloud Run.
8	Configurar identidad	Ejecutar Cloud Run utilizando la cuenta de servicio personalizada.
9	Validar	Comprobar el flujo completo: BigQuery → API → modelo → predicción → BigQuery.

5. Entregable

El entregable será el proyecto completo de la API. Debe contener todos los archivos necesarios para revisar, construir y ejecutar la solución.

Archivo / componente	Qué debe contener
API FastAPI	Código fuente de la API, incluyendo el endpoint de predicción y la lógica de integración con BigQuery.
Modelo	Archivo del modelo utilizado para realizar la predicción.
requirements.txt	Dependencias Python necesarias para ejecutar la aplicación.
Dockerfile	Definición de la imagen que permita ejecutar la API y cargar el modelo.
Imágenes	Capturas del servicio desplegado con la SA personalizada y permisos asignados a la SA.
Archivos auxiliares	Cualquier archivo adicional necesario para que la solución funcione correctamente.

6. Estructura sugerida del proyecto

La estructura puede variar; esta es solo una referencia:

```
proyecto-prediccion/
├── app/
│   ├── main.py
│   └── ...
├── model/
│   └── modelo.*
├── requirements.txt
└── Dockerfile
```

7. Consideraciones importantes

- Modelo local: el modelo debe viajar dentro de la imagen Docker y ser cargado por la API.
- Variables de entorno: no son obligatorias para esta asignación. Se permite utilizar valores configurados directamente en el código.
- Cuenta de servicio: el requisito es que Cloud Run ejecute la aplicación con la cuenta de servicio personalizada indicada. No se establece una matriz específica de permisos mínimos para la asignación.
- BigQuery: deben estar claramente identificadas la tabla de entrada y la tabla de salida.
- Reproducibilidad: el proyecto debe contener los archivos necesarios para construir la imagen y ejecutar la API.

Resultado final esperado
Una API de predicción funcional ejecutándose en Cloud Run, con el modelo incluido en la imagen Docker, construida mediante Cloud Build, almacenada en Artifact Registry, ejecutada con una cuenta de servicio personalizada, consumiendo datos desde BigQuery y almacenando las predicciones en BigQuery.